

基国鼎 —— 周报 2026/05/25 ~ 2026/05/31

本周事宜

- 在小红书集群中配置好实验环境，推进 InferTuner read world 实验
- 实习面试

下周事宜

- 推进 InferTuner read world 实验
- 思考大论文内容，改进的想法是：
 - 设计异构算力资源调度策略，部署模型或智能体时，根据机器性能与负载情况智能分配资源
 - 设计模型智能部署策略，找出最优大小模型组合和在异构算力资源上的最优放置策略
 - 设计大小模型协同与推理请求路由机制，按任务类型（查询、解释、分析、预测）及用户需求（根据 prompt 推断）智能路由到大模型或小模型（也考虑级联推理）
 - 使用多级缓存及弹性缓存优化 RAG 性能
 - 考虑多模态 Agent（待定）
 - 以上实验不再使用 Flink 而使用 Ray，因为 Ray 更加轻量且 python 原生，任务调度较为自由，同时对于异构资源特别是 GPU 的支持较好，资源调度也更灵活