基国鼎 —— 周报 2026/02/02 ~ 2026/02/08

本周事宜

- 小红书合作论文实验部分修改
  - 缓存实验部分：缓存算子进一步改进
  - Checkpoint 开销监控自动化实现
  - 修改推进程的启动形式，使 rescale 过程中推理进程保活，以此减小重配置开销
  - 将推理算子的推理框架替换为 sglang，保证能正常进行流式推理服务
- 同步阿里项目的 kv 分离与存算分离设计方案

下周事宜

- 小红书实验查漏补缺，整理归档
- 准备 Fluid 双轴会
- 阿里会议同步